

ACADEMIA DE STUDII ECONOMICE BUCUREȘTI
FACULTATEA DE CIBERNETICĂ, STATISTICĂ ȘI
INFORMATICĂ ECONOMICĂ



Analiza comportamentului clienților și fundamentarea strategiilor
de extindere pe piața hotelieră europeană

Proiect realizat de către:

Răileanu Alin-Ion

Sandu Emanuel-Petru

Cadru didactic formator:

Asistent univ. dr. Dobrița Gabriela ENE

SERIA E

Grupa 1094

București, 2026

Cuprins

INTRODUCERE.....	3
PARTEA I — PROGRAMARE PYTHON (STREAMLIT).....	5
Facilitatea 1 — Metode Streamlit interactive (afișare, grafice, widget-uri)	5
Facilitatea 2 — Pachetul geopandas (analiză geografică)	7
Facilitatea 3 — Tratarea valorilor lipsă și a valorilor extreme.....	8
Facilitatea 4 — Metode de codificare a datelor.....	11
Facilitatea 5 — Metode de scalare a datelor	13
Facilitatea 6 — Prelucrări statistice și agregare în pachetul pandas.....	15
Facilitatea 7 — Utilizarea funcțiilor de grup (apply cu funcții lambda).....	19
Facilitatea 8 — Clusterizare K-means (pachetul scikit-learn)	20
Facilitatea 9 — Regresie logistică (pachetul scikit-learn)	22
Facilitatea 10 — Regresie liniară multiplă OLS (pachetul statsmodels).....	24
PARTEA II — PROGRAMARE SAS	27
Facilitatea 1 — Crearea unui set de date SAS din fișier extern	27
Facilitatea 2 — Crearea și folosirea de formate definite de utilizator	30
Facilitatea 3 — Procesarea iterativă și condițională a datelor	31
Facilitatea 4 — Crearea de subseturi de date	33
Facilitatea 5 — Utilizarea funcțiilor SAS (ROUND, PUT, UPCASE)	34
Facilitatea 6 — Combinarea seturilor de date prin proceduri SQL.....	35
Facilitatea 7 — Utilizarea masivelor (ARRAY) pentru normalizare min-max	37
Facilitatea 8 — Proceduri de raportare (PROC FREQ, PROC REPORT)	38
Facilitatea 9 — Proceduri statistice și ML: regresia logistică (PROC LOGISTIC).....	40
Facilitatea 10 — Generarea graficelor (PROC SGPLOT, PROC SGPANEL).....	46
ANEXA A — CODUL SURSĂ SAS	49
Facilitatea 1 — PROC IMPORT și PROC CONTENTS	49
Facilitatea 2 — PROC FORMAT și aplicarea formatelor în PROC FREQ	49

Facilitatea 3 — Procesare iterativă și condițională în DATA step.....	49
Facilitatea 4 — Subseturi de date prin clauza WHERE	50
Facilitatea 5 — Funcții SAS (ROUND, PUT, UPCASE).....	50
Facilitatea 6 — Combinare prin PROC SQL (GROUP BY + INNER JOIN).....	50
Facilitatea 7 — Masive (ARRAY) pentru normalizarea min-max.....	51
Facilitatea 8 — Proceduri de raportare (PROC FREQ și PROC REPORT).....	51
Facilitatea 9 — Regresie logistică prin PROC LOGISTIC	52
Facilitatea 10 — Generarea graficelor (PROC SGPLOT, PROC SGPANEL).....	52
CONCLUZII	53
BIBLIOGRAFIE	55

INTRODUCERE

Industria hotelieră reprezintă unul dintre sectoarele cele mai sensibile la dinamica cererii, la sezonabilitate și la comportamentul de planificare al consumatorilor finali. Pentru un investitor care evaluează intrarea pe noi piețe europene, deciziile strategice, alegerea segmentului-țintă, calibrarea politicilor de preț, diferențierea ofertei pe tipologii de clientelă, nu pot fi fundamentate exclusiv pe intuiție sau pe medii agregate ale industriei. Fundamentarea cantitativă a acestor decizii necesită exploatarea datelor operaționale provenite din sistemele de gestiune hotelieră (PMS), urmată de aplicarea unor tehnici statistice și de învățare automată riguros validate.

Proiectul de față analizează un set extins de date tranzacționale provenind dintr-un lanț hotelier european format dintr-un hotel urban (City Hotel) și un complex de tip resort (Resort Hotel), cuprinzând 119.390 de rezervări realizate în intervalul iulie 2015 – august 2017. Setul de date Hotel Booking Demand conține 32 de variabile, descriind atât parametrii rezervării (lead time, durată cazare, ADR, depozit), cât și caracteristici ale clienței (țara de origine, tip de client, segment de piață, istoric anulări).

Analiza este structurată în jurul a patru obiective complementare, fiecare vizând o întrebare strategică distinctă a investitorului: (1) modelarea probabilității de anulare a unei rezervări (clasificare binară prin regresie logistică), (2) identificarea determinanților prețului mediu pe noapte (ADR) prin regresie liniară multiplă, (3) segmentarea comportamentală a clienței prin clustering nesupervizat K-means și (4) cartografierea distribuției spațiale a cererii și identificarea piețelor-sursă cu potențial de extindere prin analiză geografică.

Soluția tehnică combină două pachete software complementare. Partea în Python este construită ca aplicație web interactivă cu framework-ul Streamlit, permițând explorarea live a setului de date prin widget-uri configurabile (filtre globale, slidere pentru hiperparametri, alegerea metricii afișate pe harta geografică). Procesarea statistică se bazează pe pachetele pandas, scikit-learn, statsmodels și geopandas. Partea în SAS este realizată în mediul SAS Studio și exploatează capacitățile native ale limbajului — DATA step pentru transformări iterative, PROC SQL pentru operații relaționale, PROC LOGISTIC pentru modelarea probabilității de anulare și PROC SGPLOT/SGPANEL pentru raportarea grafică.

Documentul este structurat astfel: prezenta introducere motivează problema abordată și descrie obiectivele analizei; Partea I detaliază cele zece facilități Python implementate în aplicația Streamlit; Partea II detaliază cele zece facilități SAS implementate în pachetele de procesare; secțiunea de concluzii sintetizează rezultatele și formulează recomandări strategice

pentru investitor. Fiecare facilitate este expusă conform structurii standard — definirea problemei, informații necesare, metode și formule de calcul, prezentarea rezultatelor obținute și interpretarea economică.

PARTEA I — PROGRAMARE PYTHON (STREAMLIT)

Această parte detaliază cele zece facilități implementate în aplicația Streamlit, fiecare conform structurii standard: definirea problemei, informații necesare, metode și formule, prezentarea rezultatelor (susținută de captură de ecran) și interpretarea economică.

Facilitatea 1 — Metode Streamlit interactive (afișare, grafice, widget-uri)

a) Definirea problemei

Aplicația de analiză trebuie să ofere un mediu de explorare interactiv pentru un set extins de date hoteliere (119.390 rezervări $\times$ 32 variabile), permițând analistului să configureze parametrii fiecărei etape de procesare, să vizualizeze rezultate sub formă de grafice și tabele și să compare scenarii alternative fără a modifica codul. Soluția aleasă este pachetul Streamlit — un framework Python pentru aplicații web orientate spre date — care expune nativ widget-uri interactive (slider, radio, selectbox) și componente de afișare optimizate pentru DataFrame-uri pandas și figuri Plotly/Matplotlib, cu un cost minim de configurare.

b) Informații necesare pentru rezolvare

Pentru implementarea facilității sunt necesare: (i) instalarea pachetului streamlit împreună cu dependențele uzuale (pandas, numpy, plotly, matplotlib, seaborn); (ii) setul de date hotel_bookings.csv plasat în directorul Dataset/; (iii) modulele auxiliare din directorul src/ care încapsulează operațiunile de încărcare, curățare, codificare și modelare ale datelor.

c) Metode de calcul, algoritmi și formule utilizate

- `st.set_page_config()` — configurează layout-ul wide al aplicației și titlul paginii;
- `st.sidebar.radio()` — meniu de navigare verticală între cele nouă secțiuni;
- `st.metric()` — afișarea indicatorilor cheie (KPI) pe pagina de prezentare;
- `st.dataframe()` — randarea tabelor pandas cu lățime adaptivă și sortare;
- `st.plotly_chart()` — integrarea figurilor Plotly interactive (hover, zoom);
- `st.slider()`, `st.selectbox()`, `st.radio()`, `st.multiselect()` — controale pentru configurarea parametrilor analizei în timp real;
- `st.tabs()`, `st.columns()` — organizarea conținutului pe sub-tab-uri și coloane;
- `@st.cache_data` — caching automat al funcțiilor lente (încărcare CSV, fit ML), garantând performanța la re-interacțiune.

d) Prezentarea rezultatelor

Pagina principală a aplicației afișează cei patru indicatori cheie ai setului de date — număr total de rezervări (119.390), rata anulărilor (37,04 %), prețul mediu pe noapte (101,83 €) și numărul de țări de origine (177) — împreună cu distribuția volumului anual pe tip de hotel și sezonality lunară comparativă între rezervările onorate și cele anulate. Sidebar-ul conține meniul de navigare către cele nouă secțiuni ale aplicației și filtrele globale (tip de hotel, anotimp, interval lead time) care se propagă către secțiunile descriptive (1, 6, 7).




Figura 1.1. Pagina de prezentare a aplicației Streamlit — indicatori cheie, distribuția volumului pe ani și sezonality rezervărilor.

e) Interpretarea economică a rezultatelor

Rata de anulare observată în date — 37,04 % — se situează semnificativ peste media istorică a industriei (estimată la 20–25 %), indicând o expunere materială a operatorului hotelier la pierderi din rezervări neonorate. Distribuția lunară evidențiază o concentrare a cererii în lunile de vară (iulie–august), aspect critic pentru planificarea capacității și a strategiilor de tarificare dinamică.

Facilitatea 2 — Pachetul geopandas (analiză geografică)

a) Definirea problemei

Răspunsul la întrebarea 'de unde provin clienții și ce piețe geografice sunt cele mai atractive pentru extindere?' necesită reprezentarea spațială a datelor agregate pe țara de origine a rezervării. Choropleth-ul este reprezentarea standardă pentru date numerice asociate unor regiuni geografice și se obține prin suprapunerea unei scheme de culori peste un set de geometrii poligonale, raportându-se la o variabilă cantitativă (volum, rata anulării, preț mediu). Pachetul geopandas este referința în ecosistemul Python pentru manipularea datelor geospatiale, oferind o extensie a structurilor pandas cu o coloană dedicată geometriilor (poligoane, linii, puncte) și integrare nativă cu Shapely și PyProj.

b) Informații necesare pentru rezolvare

Sunt necesare următoarele resurse: (i) shapefile-ul Natural Earth la rezoluția de 110 m (ne_110m_admin_0_countries.shp) — conține geometriile poligonale ale tuturor țărilor lumii împreună cu atributul ISO_A3 (codul ISO 3166-1 alpha-3); (ii) coloana country din datasetul curățat, deja exprimată în codificare ISO-3; (iii) statisticile agregate per țară — volum (count), rata anulării (mean), preț mediu (mean).

c) Metode de calcul, algoritmi și formule utilizate

- `gpd.read_file(SHAPEFILE_PATH)` — încărcarea shapefile-ului ca GeoDataFrame;
- `df.groupby('country').agg(volum=..., cancel_rate=..., avg_adr=...)` — agregarea statisticilor pe țară;
- `world.merge(country_stats, left_on='ISO_A3', right_on='country', how='left')` — îmbinarea geometriilor cu statisticile;
- `GeoDataFrame.to_json()` — serializarea în format GeoJSON pentru consumul Plotly;
- `plotly.express.choropleth(geojson=..., locations='country', featureidkey='properties.ISO_A3', color='display_value', color_continuous_scale=cmap)` — randarea interactivă cu hover personalizat.

d) Prezentarea rezultatelor

Aplicația oferă utilizatorului trei metrice alternative pe hartă (volum, rata anulărilor, preț mediu), schimbabile printr-un control `st.radio`. În varianta volumului, cinci țări concentrează aproximativ 75 % din rezervări: Portugalia (~ 40 %), Marea Britanie (~ 10 %), Franța (~ 9 %), Spania (~ 7 %) și Germania (~ 7 %). Matricea strategică afișată sub hartă plasează țările (cu $\text{volum} \geq 100$ rezervări) pe planul $\text{volum} \times \text{preț mediu}$, colorat după rata anulărilor,

identificând cadranul dreapta-sus (volum mare, preț mare, anulări puține) ca țintă prioritară de extindere.




Figura 2.1. Choropleth Natural Earth încărcat prin geopandas și convertit în GeoJSON, suprapus cu matricea strategică volum × preț × rata anulărilor.

e) Interpretarea economică a rezultatelor

Concentrarea geografică a clientelei pe cinci țări europene indică, pe de o parte, oportunitatea consolidării relațiilor comerciale și a campaniilor localizate de marketing pe aceste piețe-sursă, iar pe de altă parte expunerea la un risc de concentrare. O strategie prudentă de extindere ar viza diversificarea către piețele cu volum mediu și rată redusă a anulărilor identificate prin matricea strategică, reducând astfel dependența operatorului față de cererea portugheză (aproximativ 40 % din volum) și de fluctuațiile macroeconomice ale unei singure economii.

Facilitatea 3 — Tratarea valorilor lipsă și a valorilor extreme

a) Definirea problemei

Datasetul Hotel Booking Demand conține valori lipsă în patru coloane (children, country, agent, company) cu procente foarte diferite (de la 0,003 % la 94 %), precum și valori

extreme în variabila ADR (preț pe noapte) cu un maxim observat de 5.400 €/noapte — implauzibil pentru segmentul de hoteluri reprezentat. Absența unei strategii diferențiate de imputare, alături de păstrarea valorilor extreme, ar distorsiona statistici descriptive, ar genera coeficienți OLS instabili dominați de câteva observații atipice și ar reduce capacitatea predictivă a modelelor supervizate aplicate ulterior.

b) Informații necesare pentru rezolvare

Pentru audit și tratare sunt necesare: rezultatele apelurilor `df.isna().sum()` (distribuția valorilor lipsă pe coloană) și `df['adr'].describe()` (statistici descriptive ale variabilei target); cunoștințe domain referitoare la semantica fiecărei coloane (în industria hotelieră, NaN pe agent reprezintă o rezervare directă fără intermediar, deci o categorie semantică reală, nu o valoare lipsă în sens statistic).

c) Metode de calcul, algoritmi și formule utilizate

- Drop al coloanei company (94 % NaN): sparsitate excesivă o face neutilizabilă;
- Imputare semantică agent.fillna(0): NaN $\equiv$ rezervare directă, transformat în categoria 0;
- Imputare cu moda pe country: country.fillna(mode), păstrând tiparul dominant PRT (Portugalia);
- Drop pe rândurile cu NaN pe children (doar 4 rânduri, 0,003 %);
- Regula Tukey $1,5 \times \text{IQR}$ pentru ADR: prag superior = $Q3 + 1,5 \cdot (Q3 - Q1) \approx 224$ €;
- Filtrare a rândurilor fără sens de business: `oaspeți = 0 SAU stays_in_weekend_nights + stays_in_week_nights = 0`;
- Pipeline-ul este implementat în modulul `src/cleaning.py` prin funcția `clean_pipeline()`.

d) Prezentarea rezultatelor

Strategia este controlabilă din aplicație printr-un control `st.radio` cu patru opțiuni ($1,5 \cdot \text{IQR}$, $3,0 \cdot \text{IQR}$, prag fix 1.000 €, fără filtru), permițând explorarea sensibilității rezultatelor la pragul ales. Sub configurația implicită (regula Tukey), datasetul curățat conține aproximativ 118.500 de rânduri ($-0,7$ % față de cele 119.390 inițiale), cu mediana ADR stabilă la ≈ 95 € și maximul redus la pragul calculat. Boxplot-ul comparativ înainte/după demonstrează vizual eliminarea cozii lungi de outlieri.

1. Prezentare

2. Calitatea datelor

3. Curățare

4. Codificare

5. Scalare

6. Statistici & Group-by

7. Analiză geografică

8. Segmentare K-means

9. Predicții (LogReg + OLS)

Filtre globale

Aplicate doar în secțiunile 1, 6, 7 (descriptive/vizualizare).

Hotel

Toate

Anotimp

Choose options


Zile între rezervare și sosire

0737


Curățare configurabilă în secțiunea 3. Modelele (sect. 8, 9) rulează pe dataset complet curățat, NU filtrat — pentru reproducibilitate.



2. Distribuția variabilelor categorice



3. Distribuții ale variabilelor numerice cheie



Figurile 3.1 și 3.2. (1) Auditul calității datelor — distribuția valorilor lipsă, distribuțiile categoricelor (pie chart-uri), distribuțiile variabilelor numerice cheie, scatter bivariat $lead_time \times ADR$ colorat după anulare și avertismentul de data leakage; (2) Strategia de curățare cu tabelul deciziilor și boxplot-ul ADR comparativ înainte/după aplicarea pipeline-ului.

e) Interpretarea economică a rezultatelor

Eliminarea celor 6 % outlieri din coada superioară a distribuției ADR stabilizează estimările prețului mediu și permite construirea unor intervale de încredere realiste pentru deciziile de tarificare. Imputarea semantică a coloanei agent (NaN tratat ca rezervare directă) păstrează informația privind canalul de distribuție — variabilă predictivă valoroasă pentru segmentare. Drop-ul coloanei company (94 % sparsă) elimină zgomot fără pierdere informațională substanțială, întrucât mai puțin de 6 % din rezervări provin din contracte corporate.

Facilitatea 4 — Metode de codificare a datelor

a) Definirea problemei

Modelele econometrice și de învățare automată folosite ulterior (regresie logistică, regresie OLS, K-means) operează exclusiv cu input numeric. Conversia variabilelor categorice în reprezentări numerice — codificarea — trebuie realizată diferențiat în funcție de cardinalitatea variabilei (numărul de valori unice) și de existența unei ordini intrinseci între valori. O codificare uniformă (de exemplu LabelEncoder aplicat tuturor variabilelor) ar introduce relații artificiale de ordine între categorii nominale, distorsionând coeficienții liniari și distanțele euclidiene folosite în clustering.

b) Informații necesare pentru rezolvare

Sunt necesare: datasetul curățat în urma facilității 3, dicționarele de mapare pentru variabilele ordinale ($deposit_type \rightarrow \{\text{No Deposit: 0, Refundable: 1, Non Refund: 2}\}$) și pentru luna calendaristică ($string \rightarrow int\ 1...12$), precum și frecvențele empirice ale categoriilor pentru codificarea country.

c) Metode de calcul, algoritmi și formule utilizate

- Codificare binară manuală pentru hotel (cardinalitate 2): $is_resort = (hotel == 'Resort Hotel').astype(int)$;
- One-Hot Encoding pentru variabile nominale fără ordine (meal, market_segment, distribution_channel, customer_type, reserved_room_type, assigned_room_type) prin

`pd.get_dummies(..., drop_first=True)` — elimină coloana de referință pentru a evita multicoliniaritatea perfectă;

- Codificare ordinală manuală pentru `deposit_type`, păstrând ordinea de commitment financiar crescător;
- Frequency Encoding pentru `country` (≈ 178 valori): `country_freq = country.map(country.value_counts(normalize=True))` — păstrează informația de prevalență într-o singură coloană numerică, evitând explozia dimensională a One-Hot;
- Codificare ciclică pentru `arrival_date_month`: `month_sin = sin(2 $\pi$ ·m/12)`, `month_cos = cos(2 $\pi$ ·m/12)` — păstrează adiacența între Decembrie și Ianuarie.

d) Prezentarea rezultatelor

Aplicarea pipeline-ului produce un dataset cu aproximativ 50 de coloane numerice (de la cele 30 inițiale, după drop-uri și encoding-uri). Tabelul interactiv din aplicație permite inspectarea, variabilă cu variabilă, a valorilor înainte și după codificare, evidențiind exact structura transformării (de exemplu, pentru `country` se vede valoarea numerică a frecvenței empirice; pentru `month` se văd cele trei coloane derivate `month_num`, `month_sin`, `month_cos`).




Figura 4.1. Tabelul celor cinci strategii de codificare și panoul de inspecție pentru o variabilă aleasă de utilizator.

e) Interpretarea economică a rezultatelor

Alegerea strategiei de codificare are impact economic direct: ordinalitatea atribuită corect coloanei `deposit_type` permite modelului să cuantifice incrementul de risc de anulare asociat fiecărui pas (No Deposit → Refundable → Non Refund), iar codificarea ciclică a lunii prezervă fenomenul sezonality calendaristice — esențial în industria turismului, unde Decembrie și Ianuarie aparțin aceleiași sezon comercial. O codificare greșită (LabelEncoder pe toate variabilele) ar fi denaturat magnitudinea coeficienților OLS cu un factor de 2–3, conducând la decizii de pricing eronate.

Facilitatea 5 — Metode de scalare a datelor

a) Definirea problemei

Algoritmii bazați pe distanță (K-means) și pe optimizare prin gradient descent (regresia logistică) sunt sensibili la diferențele de scară între variabile. Variabila `lead_time` variază în intervalul [0; 737] zile, în timp ce `total_guests` rar depășește valoarea 5; în lipsa scalării, contribuția `lead_time` la distanța euclidiană domină total contribuția tuturor celorlalte variabile, conducând la clustere triviale tăiate perpendicular pe această axă și ignorând structura reală a comportamentului de rezervare. Regresia OLS nu necesită scalare pentru a funcționa, dar scalarea facilitează compararea relativă a coeficienților standardizați.

b) Informații necesare pentru rezolvare

Sunt necesare: datasetul codificat în urma facilității 4 (toate variabilele numerice), pachetul `sklearn.preprocessing` care expune clasele `StandardScaler` și `MinMaxScaler`, precum și disciplina anti-leakage de a fi aplicat scaler-ul exclusiv pe setul de antrenament și de a-l aplica nemodificat pe setul de test.

c) Metode de calcul, algoritmi și formule utilizate

- `StandardScaler` (Z-score): $x_std = (x - \mu) / \sigma$, unde μ și σ sunt media și deviația standard pe setul de antrenament. Rezultatul are media zero și varianța unitară pe fiecare coloană;
- `MinMaxScaler`: $x_mm = (x - \min) / (\max - \min)$, aducând toate valorile în intervalul [0, 1]; util atunci când distribuția nu este gaussiană și se dorește limitarea sensibilității la outliers (deja eliminați în facilitatea 3);
- Pipeline anti-leakage: `scaler.fit_transform(X_train)` urmat de `scaler.transform(X_test)`; funcția `scale_features()` din `src/scaling.py` încapsulează acest pattern.

d) Prezentarea rezultatelor

Comparația statisticilor înainte/după scalare confirmă comportamentul teoretic: StandardScaler aduce media la valori apropiate de zero ($|\mu| < 10^{-15}$) și deviația standard la 1,0 pentru toate variabilele (lead_time, ADR, total_nights, total_guests); MinMaxScaler aliniază toate valorile în [0, 1]. Demo-ul comparativ al algoritmului K-means cu și fără scalare evidențiază vizual dominanța lead_time-ului asupra clusterelor în absența standardizării.




Figura 5.1. Comparația distribuțiilor înainte și după scalare, împreună cu demonstrația efectului scalării asupra clusterelor K-means.

e) Interpretarea economică a rezultatelor

Fără scalarea adecvată, algoritmul de segmentare ar fi grupat clienții exclusiv pe baza ferestrei de rezervare (lead time), ignorând în totalitate informația de preț plătit, durata sejurului și mărimea grupului — o segmentare unidimensională care nu ar fi servit nici uneia dintre deciziile strategice ale operatorului hotelier. Standardizarea face ca toate cele patru dimensiuni comportamentale să contribuie egal la formarea profilurilor de client, generând segmente acționabile (Last-minute · Preț scăzut, Termen-lung · Preț ridicat, Sejur prelungit · Grup mare etc.).

Facilitatea 6 — Prelucrări statistice și agregare în pachetul pandas

a) Definirea problemei

Înainte de aplicarea modelelor predictive, este necesară o etapă de analiză exploratorie a datelor (Exploratory Data Analysis) care să identifice structurile sistematice, asimetriile și corelațiile relevante pe care urmează să se construiască raționamentul economic. Agregările tabulare (`groupby`, `pivot_table`) permit cuantificarea diferențelor comportamentale între segmente ($\text{hotel} \times \text{lună}$, $\text{segment} \times \text{tip depozit}$, țări de origine), iar matricea de corelație Pearson evaluează multicolaritatea predictorilor înaintea regresiei OLS.

b) Informații necesare pentru rezolvare

Sunt necesare: datasetul curățat, funcțiile native ale pachetului pandas (`groupby`, `agg`, `pivot_table`, `corr`), categoriile de tip ordinal pentru luni (prin `pd.Categorical`) și filtrele globale aplicate din sidebar (`hotel`, `anotimp`, `lead time`) care propagă subsetul activ către secțiune.

c) Metode de calcul, algoritmi și formule utilizate

- `df.groupby(['hotel','arrival_date_month'])['is_canceled'].agg(['mean','count'])`: agregare bi-dimensională pentru rata anulărilor pe perechi $\text{hotel} \times \text{lună}$;
- `df.pivot_table(values='adr',index='market_segment',columns='deposit_type',aggfunc='mean')`: tabel pivot pentru prețul mediu segmentat;
- `df.groupby('country').agg(volum=...,rata_anulare=..., pret_mediu=...) .sort_values('volum', ascending=False).head(10)`: top 10 țări după volum cu metrici asociate;
- `df.corr()` pe coloanele numerice principale: matrice de corelație Pearson $\rho_{XY} = \text{Cov}(X,Y) / (\sigma_X \cdot \sigma_Y)$;
- `px.sunburst(path=['Hotel','Segment','Stare'], values='Volum')`: diagramă ierarhică pe trei niveluri pentru vizualizarea distribuției comportamentului.

d) Prezentarea rezultatelor

Selectorul interactiv permite parcurgerea celor șase perspective de analiză. Heatmap-ul $\text{Hotel} \times \text{Lună}$ evidențiază o rată superioară a anulărilor pentru City Hotel comparativ cu Resort, cu variație lunară marcată (vârf în vară). Tabelul pivot $\text{Segment} \times \text{Deposit}$ arată prețuri medii sistematic mai mici pe segmentele Online TA și Groups față de Direct și Corporate. Top 10 țări confirmă dominanța Portugaliei, urmată de piețele europene-cheie. Matricea de corelație validează lipsa multicolarității între predictorii principali (toate corelațiile între predictorii sub 0,40 în valoare absolută).

1. Prezentare

2. Calitatea datelor

3. Curățare

4. Codificare

5. Scalare

6. Statistici & Group-by

7. Analiză geografică

8. Segmentare K-means

9. Predicții (LogReg + OLS)

Filtre globale

Aplicate doar în secțiunile 1, 6, 7 (descriptive/vizualizare).

Hotel

Toate

Anotimp

Choose options

Zile între rezervare și sosire

0737

Curățare configurabilă în secțiunea 3. Modelele (sect. 8, 9) rulează pe dataset complet curățat, NU filtrat — pentru reproducibilitate.

Deploy

```
groupby().agg(), pivot_table() și apply(Lambda) . Filtre globale se aplică.
```

Alege dimensiunea analizei:


Hotel × Lună — rata anulărilor

Rata anulărilor pe Hotel × Lună

```
df.groupby(['hotel', 'arrival_date_month'])['is_canceled'].agg(['mean', 'count'])
```

Hotel	Luna sosirii	Rata anulărilor	Volum rezervări
City Hotel	January	0.3989	3708
City Hotel	February	0.3855	4897
City Hotel	March	0.3716	6373
City Hotel	April	0.4648	7315
City Hotel	May	0.4448	7973
City Hotel	June	0.4481	7706
City Hotel	July	0.4123	7860
City Hotel	August	0.4048	8644
City Hotel	September	0.423	7263
City Hotel	October	0.4323	7495
City Hotel	November	0.385	4296
City Hotel	December	0.4245	4075
Resort Hotel	January	0.1501	2159

Vizualizare — heatmap interactiv



1. Prezentare

2. Calitatea datelor

3. Curățare

4. Codificare

5. Scalare

6. Statistici & Group-by

7. Analiză geografică

8. Segmentare K-means

9. Predicții (LogReg + OLS)

Filtre globale

Aplicate doar în secțiunile 1, 6, 7 (descriptive/vizualizare).

Hotel

Toate

Anotimp

Choose options

Zile între rezervare și sosire

0737

Curățare configurabilă în secțiunea 3. Modelele (sect. 8, 9) rulează pe dataset complet curățat, NU filtrat — pentru reproducibilitate.

Deploy

Analiza pieței hoteliere

Statistici descriptive & analize de grup

```
groupby().agg(), pivot_table() și apply(Lambda) . Filtre globale se aplică.
```

Alege dimensiunea analizei:

Segment × Tip depozit — preț mediu (pivot_table)

Preț mediu pe noapte — Segment × Tip depozit

```
df.pivot_table(values='adr', index='market_segment', columns='deposit_type', aggfunc='mean')
```

Preț mediu pe noapte (€) — segment de piață × tip depozit

Segment de piață	No Deposit	Non Refund	Refundable
Aviation	102.7		
Complementary	3.0		
Corporate	68.6	89.2	81.8
Direct	106.6	96.7	89.2
Groups	74.4	84.0	66.0
Offline TA/TO	83.9	98.9	76.1
Online TA	111.5	90.6	123.5

Navigare proiect

1. Prezentare

2. Calitatea datelor

3. Curățare

4. Codificare

5. Scalare

6. Statistici & Group-by

7. Analiză geografică

8. Segmentare K-means

9. Predicții (LogReg + OLS)

Filtre globale

Aplicate doar în secțiunile 1, 6, 7 (descriptive/vizualizare).

Hotel

Toate

Anotimp

Choose options

Zile între rezervare și sosire

0737

Curățare configurabilă în secțiunea 3. Modelele (sect. 8, 9) rulează pe dataset complet curățat, NU filtrat — pentru reproducibilitate.

Analiza pieței hoteliere

Statistici descriptive & analize de grup

groupby().agg(), pivot_table() și apply(lambda). Filtrele globale se aplică.

Alege dimensiunea analizei:

Top 10 țări — volum, rata anulărilor, preț mediu

Top 10 țări după volum de rezervări

df.groupby('country').agg(volum=('is_canceled','count'), rata_anulare=('is_canceled','mean'), pret_mediu=('adr','mea

Țara (ISO-3)	Volum rezervări	Rata anulărilor	Preț mediu / noapte (€)
PRT	47095	57.36	88.48
GBR	11805	19.69	92.69
FRA	10105	18.25	106.08
ESP	7867	24.43	105.9
DEU	7192	16.53	102.71
ITA	3652	35.3	110.58
IRL	3304	24.49	95.36
BEL	2282	20.03	110.72
BRA	2156	37.62	107.65
NLD	2051	18.14	104.87

Top 10 țări — volum și rata anulărilor (intensitate culoare)

Navigare proiect

1. Prezentare

2. Calitatea datelor

3. Curățare

4. Codificare

5. Scalare

6. Statistici & Group-by

7. Analiză geografică

8. Segmentare K-means

9. Predicții (LogReg + OLS)

Filtre globale

Aplicate doar în secțiunile 1, 6, 7 (descriptive/vizualizare).

Hotel

Toate

Anotimp

Choose options

Zile între rezervare și sosire

0737

Curățare configurabilă în secțiunea 3. Modelele (sect. 8, 9) rulează pe dataset complet curățat, NU filtrat — pentru reproducibilitate.

Analiza pieței hoteliere

Statistici descriptive & analize de grup

groupby().agg(), pivot_table() și apply(lambda). Filtrele globale se aplică.

Alege dimensiunea analizei:

Matrice de corelație între variabilele numerice

Matrice de corelație Pearson

Verificăm multicolaritatea între predictorii înainte de regresie.

Coefficienți Pearson între variabilele numerice principale

Corelații negative: is_canceled ↔ total_of_special_requests, required_car_parking_spaces. Pozitivă: lead_time ↔ is_canceled. Corelațiile dintre predictorii sunt slabe — multicolaritatea redusă.

17

Facilitatea 7 — Utilizarea funcțiilor de grup (apply cu funcții lambda)

a) Definirea problemei

Calculul unor indicatori econometrici personalizați — precum coeficientul de variație ($CV = \sigma/\mu$), folosit în literatura financiară ca măsură standardizată a volatilității prețurilor — nu poate fi exprimat prin agregările standard din metoda `.agg()`. Necesită aplicarea unei funcții definite de utilizator (anonimă, prin sintaxa lambda) pe fiecare grup rezultat din `.groupby()`, funcție care returnează simultan mai mulți indicatori. Pachetul pandas permite acest pattern prin metoda `.apply()` combinată cu `pd.Series` ca obiect-retur.

b) Informații necesare pentru rezolvare

Sunt necesare: datasetul curățat cu coloanele `market_segment`, `adr`, `total_of_special_requests`; cunoștințe asupra interpretării economice a coeficientului de variație în contextul pricینگului hotelier.

c) Metode de calcul, algoritmi și formule utilizate

- `df.groupby('market_segment').apply(lambda x: pd.Series({...}))`: aplică funcția lambda pe fiecare subgrup și returnează un DataFrame multi-coloană;
- Coeficientul de variație: $CV = \sigma(ADR) / \mu(ADR) \cdot 100 (\%)$;
- Procentul clienților implicați: $pct = (x['total_of_special_requests'] > 0).mean() \cdot 100 (\%)$;
- Volumul rezervărilor: `len(x)`;
- Sortare descrescătoare după volum pentru prezentarea în tabel.

d) Prezentarea rezultatelor

Tabelul rezultat afișează pentru fiecare segment de piață prețul mediu (în €), volatilitatea (CV, exprimat ca procent), procentul clienților care fac cereri speciale (indicator de engagement) și volumul de rezervări. Segmentul Online TA (volumul cel mai mare, $\approx 56\%$) prezintă o volatilitate medie a prețului, în timp ce segmentul Direct concentrează cele mai multe cereri speciale (engagement ridicat). Segmentele Groups și Complementary prezintă coeficienți de variație extremi, semnalând pricing eterogen.




Figura 7.1. Rezultatul aplicării funcției lambda pe groupby — trei indicatori econometrici personalizați per segment.

e) Interpretarea economică a rezultatelor

Coeficientul de variație acționează ca un indicator de risc al tarifării: segmente cu CV peste 40 % au pricing eterogen (oferte ad-hoc, negocieri individuale), iar segmente cu CV sub 20 % au pricing standardizat (pachete fixe). Combinat cu procentul de engagement, indicatorul oferă investitorului o hartă a comportamentului tarifar pe care se poate construi o politică unitară de pricing: segmente high-CV necesită automatizarea regulilor de tarificare (yield management), iar segmente high-engagement sunt candidate la programe de loialitate.

Facilitatea 8 — Clusterizare K-means (pachetul scikit-learn)

a) Definirea problemei

Identificarea profilurilor comportamentale recurente ale clientelei — neevidente la o inspecție tabulară a celor 119.390 de rezervări — este un caz tipic de învățare nesupervizată. Algoritmul K-means partiționează spațiul observațiilor în K clustere care minimizează inerția totală intra-cluster (suma pătratelor distanțelor euclidiene la centroid). Două dificultăți tehnice

trebuie rezolvate: (1) alegerea numărului optim de clustere K , (2) interpretarea business a centroizilor obținuți pe scara standardizată.

b) Informații necesare pentru rezolvare

Sunt necesare: cele patru variabile comportamentale ale rezervării — `lead_time`, `adr`, `total_nights`, `total_guests` — standardizate prin `StandardScaler` (facilitatea 5); clasele `KMeans` și `silhouette_score` din `sklearn`; opțional, scaler-ul pentru aplicarea `inverse_transform` asupra centroizilor în vederea interpretării.

c) Metode de calcul, algoritmi și formule utilizate

- Metoda Elbow — calculul inerției $WCSS = \sum_i \sum_{x \in C_i} \|x - \mu_i\|^2$ pentru $K \in \{2, \dots, 10\}$, urmată de detecția automată a punctului de îndoire prin metoda distanței față de coarda care unește extremele;
- Scorul Silhouette — pentru fiecare observație x : $s(x) = (b - a) / \max(a, b)$, unde a este distanța medie intra-cluster și b distanța medie la cel mai apropiat cluster vecin; raportat ca medie pe întregul eșantion;
- `KMeans(n_clusters=K, init='k-means++', n_init=3, algorithm='elkan', random_state=42)`: inițializare smart și optimizare prin inegalitatea triunghiulară pentru viteză;
- `Inverse transform` al centroizilor pentru interpretarea pe scara originală (zile, euro, nopți, oaspeți);
- Derivarea automată a denumirilor de cluster prin compararea valorii fiecărei axe cu media populației de clustere.

d) Prezentarea rezultatelor

Curba Elbow detectează automat punctul de îndoire în jurul valorii $K = 5$; scorul Silhouette atinge maximul la $K = 6$. Valoarea de echilibru aleasă ca implicită este $K = 4$, oferind un compromis bun între granularitate (suficient pentru a distinge profile clar diferite) și interpretabilitate (suficient de puține pentru ca fiecare cluster să primească o denumire business). Profilurile rezultate sunt diferențiate prin lead time (planificare versus last-minute), preț pe noapte (premium versus buget) și durata sejurului.



Figura 8.1. Selectarea K prin metoda Elbow și scor Silhouette, împreună cu tabelul profilurilor de cluster (denumire automată, volum, rata anularilor, valorile centroizilor pe scara originală).

e) Interpretarea economică a rezultatelor

Segmentarea permite construirea unei strategii de retenție diferențiate. Clusterelor cu lead time mare și ADR ridicat reprezintă clienții cu valoare ridicată pe durata vieții (high lifetime value); aceștia merită investiții în programe de loialitate. Clusterelor Last-minute · Preț scăzut au rate de anulare semnificativ mai mari și pot fi gestionate prin politica obligatorie de depozit non-refundabil. Segmentul Sejur-prelungit · Grup-mare este candidat la pachete tarifare integrate (cazare + activități + transfer).

Facilitatea 9 — Regresie logistică (pachetul scikit-learn)

a) Definirea problemei

Predicția probabilității de anulare a unei rezervări este o problemă clasică de clasificare binară, în care variabila țintă is_canceled ia valori {0, 1}. Regresia logistică modelează relația dintre vectorul de predictor X și probabilitatea condiționată $P(Y = 1 | X)$ printr-o funcție sigmoidă aplicată unei combinații liniare a predictorilor. Avantajul față de modele mai

complexe (arbori, ensembluri) constă în interpretabilitatea directă a coeficienților: coeficientul standardizat asociat fiecărei variabile măsoară contribuția acesteia la log-odds-ul anulării.

b) Informații necesare pentru rezolvare

Sunt necesare: setul de cincisprezece predictori derivați (lead_time, adr, total_nights, total_guests, is_resort,, deposit_type_ord,, previous_cancellations, previous_bookings_not_canceled, booking_changes, required_car_parking_spaces, total_of_special_requests, country_freq, month_sin, month_cos, is_repeated_guest); clasele LogisticRegression, StandardScaler, train_test_split, confusion_matrix, classification_report, roc_auc_score, roc_curve din scikit-learn.

c) Metode de calcul, algoritmi și formule utilizate

- Funcția sigmoidă: $P(Y=1|X) = 1 / (1 + \exp(-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)))$;
- Estimarea coeficienților prin maximum-likelihood: maximizarea log-verosimilității $\ell(\beta) = \sum [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$;
- Split train/test 80/20 cu stratificare după ținta y (păstrează rata anulărilor în ambele subseturi);
- Pipeline anti-leakage: StandardScaler.fit pe train, .transform pe test;
- class_weight='balanced' — re-ponderează clasele invers proporțional cu frecvența, reflectând costul asimetric al ratării unei anulări (pierdere revenue) versus cost fals-positiv (contact inutil);
- Pragul de decizie ajustabil interactiv prin slider (default 0,40) — controlează compromisul precision/recall.

d) Prezentarea rezultatelor

La pragul implicit de 0,40, modelul atinge un ROC AUC de aproximativ 0,84, o acuratețe globală de circa 72 %, un recall pe clasa anulărilor de aproximativ 79 % (din toate anulările reale, 79 % sunt corect identificate) și o precizie pe clasa anulărilor de circa 60 %. Top trei predictori după magnitudinea coeficientului standardizat sunt: tipul depozitului (Non Refund scade puternic riscul de anulare), istoricul anulărilor anterioare (puternic predictiv pozitiv) și frecvența țării (efect mediat de sezonabilitatea pieței).




Figura 9.1. Modelul de regresie logică — indicatori cheie, matrice de confuzie, curbă ROC și top 10 predictorii cu interpretare business asociată.

e) Interpretarea economică a rezultatelor

Modelul probabilistic permite operatorului hotelier să implementeze un sistem de scoring pentru fiecare rezervare nouă: rezervările cu probabilitate predictivă de anulare peste 40 % pot fi marcate automat pentru intervenție preventivă (apel telefonic de confirmare, ofertă de upgrade gratuit, reminder cu 14/7 zile înainte de check-in). Estimarea conservatoare a literaturii arată că o reducere de 15–20 % a ratei de anulare pe segmentul marcat se traduce în recuperarea unui procent semnificativ din pierderile anuale. Coeficientul puternic negativ al variabilei `deposit_type_ord` fundamentează strategia de încurajare a depozitelor non-refundabile prin reduceri tarifare moderate (de exemplu, –5 %).

Facilitatea 10 — Regresie liniară multiplă OLS (pachetul statsmodels)

a) Definirea problemei

Cuantificarea contribuției fiecărui factor la formarea prețului mediu pe noapte (ADR) este o problemă de regresie liniară multiplă, în care ADR este variabila dependentă explicată printr-o combinație liniară a predictorilor identificați în etapele anterioare. Spre deosebire de

scikit-learn, pachetul statsmodels oferă rapoarte econometrice complete: coeficienții estimați, erorile standard, statisticile t, p-value-urile, intervalele de încredere, R^2 și R^2 ajustat, statistica F a modelului — elemente esențiale pentru raportarea academică a rezultatelor.

b) Informații necesare pentru rezolvare

Sunt necesare: datasetul codificat (toți predictorii numerici), pachetul statsmodels.formula.api (specificarea modelului prin formulă în stil R), instrumente de diagnostic pe reziduuri pentru verificarea ipotezei de homoscedasticitate. Se construiesc două variante ale modelului: una pe ADR brut (interpretabil direct în euro) și una pe $\log(\text{ADR} + 1)$ (recomandată în cazul reziduurilor heteroscedastice).

c) Metode de calcul, algoritmi și formule utilizate

- Specificarea modelului: `smf.ols(formula='adr ~ lead_time + total_nights + total_guests + is_resort + deposit_type_ord + ... + month_sin + month_cos + country_freq', data=df_train);`
- Estimarea OLS prin metoda celor mai mici pătrate: $\beta = (X^T X)^{-1} X^T y$;
- Metrice de adecvare: $R^2 = 1 - \text{SSR}/\text{SST}$, R^2 ajustat = $1 - (1 - R^2) \cdot (n - 1) / (n - p - 1)$;
- $\text{MAE} = (1/n) \sum |y_i - \hat{y}_i|$, $\text{RMSE} = \sqrt{(1/n) \sum (y_i - \hat{y}_i)^2}$ calculate pe setul de test;
- Transformarea logaritmică: $y_{\log} = \ln(\text{adr} + 1)$ cu back-transform $\hat{y}_{\text{eur}} = \exp(\hat{y}_{\log}) - 1$ pentru compararea onestă a celor două variante;
- Diagnostic reziduuri: scatter reziduuri vs valori prezise pentru detecția vizuală a heteroscedasticității (lățire spre dreapta).

d) Prezentarea rezultatelor

Modelul A (ADR brut) atinge un R^2 ajustat de aproximativ 0,40, cu MAE pe test ≈ 28 € și RMSE ≈ 38 €. Modelul B (log) prezintă reziduuri mai uniforme, cu R^2 al modelului în jur de 0,52 și un MAE back-transformat comparabil cu Modelul A. Coeficienții semnificativi statistic ($p < 0,05$) includ: total_guests (efect pozitiv puternic, fiecare oaspete adițional crescând ADR-ul), is_resort (resort cu preț mediu superior city), deposit_type_ord, sezonabilitatea (month_sin, month_cos), country_freq.




Figura 10.1. Regresia OLS — tabelul comparativ Model A (raw) versus Model B (log), diagnosticul reziduurilor side-by-side și coeficienții semnificativi statistic.

e) Interpretarea economică a rezultatelor

Modelul OLS oferă o cuantificare directă a efectelor marginale: fiecare oaspete adițional adaugă în medie X € la prețul rezervării, iar o rezervare la resort este în medie cu Y € mai scumpă decât una la city hotel, ceteris paribus. Aceste cifre fundamentează deciziile de pricing diferențiat (familie de patru versus cuplu, resort versus city) și permit evaluarea ex-ante a impactului unor schimbări de politică (de exemplu, introducerea unui depozit non-refundabil în segmentele cu preț mediu scăzut). R^2 ajustat de aproximativ 0,40 indică o capacitate explicativă moderată — așteptată în industria hotelieră, unde tarifele finale depind și de factori micro neînregistrați în date (orașe-eveniment, promoții punctuale, contracte negociate).

PARTEA II — PROGRAMARE SAS

Această parte detaliază cele zece facilități SAS implementate în mediul SAS On Demand, conform aceleiași structuri standard. Toate procedurile rulează pe biblioteca proiect, populată inițial cu setul de date `hotel_bookings.csv` importat în facilitatea 1.

Facilitatea 1 — Crearea unui set de date SAS din fișier extern

a) Definirea problemei

Înainte de orice procesare, datele tranzacționale trebuie importate într-un format propriu pachetului SAS care să garanteze integritatea tipurilor, eficiența operațiilor ulterioare și compatibilitatea cu procedurile specifice. Setul de date Hotel Booking Demand este disponibil în format CSV — un format text universal, dar care nu transmite explicit tipurile de date — și conține 119.390 de înregistrări $\times$ 32 variabile heterogene (numerice și alfanumerice), unele cu valori lipsă.

b) Informații necesare pentru rezolvare

Sunt necesare: fișierul `hotel_bookings.csv` încărcat în storage-ul SAS On Demand (calea `/home/u64504352/Proiect_pachete/`), biblioteca persistentă proiect destinată stocării seturilor de date generate, precum și procedura `PROC IMPORT` configurată cu opțiunea `GUESSINGROWS=MAX` (parcurge întregul fișier pentru deducerea tipurilor).

c) Metode de calcul, algoritmi și formule utilizate

- `PROC IMPORT DATAFILE=... OUT=proiect.rezervari_brute DBMS=CSV REPLACE;` — importul efectiv al fișierului;
- `GUESSINGROWS=MAX` — instrucțiunea care forțează parsarea tuturor rândurilor pentru inferarea corectă a tipurilor de date (esențială când valorile categorice apar abia după mii de rânduri);
- `GETNAMES=YES` — preluarea numelor coloanelor din primul rând;
- `PROC CONTENTS DATA=proiect.rezervari_brute` — listare descriptivă a structurii.

d) Prezentarea rezultatelor

În urma rulării procedurii, setul de date `proiect.rezervari_brute` conține cele 119.390 înregistrări și 32 de variabile cu tipurile corect deduse. Procedura `PROC CONTENTS` produce listarea alfabetică a variabilelor cu informații despre tip (`Char/Num`), lungime, format și informat, confirmând că variabilele numerice (`lead_time`, `adr`, `total counts`) sunt stocate ca `Num` iar cele alfanumerice (`hotel`, `country`, `market_segment`) ca `Char`.

Alphabetic List of Variables and Attributes					
#	Variable	Type	Len	Format	Informat
28	adr	Num	8	BEST12.	BEST32.
10	adults	Num	8	BEST12.	BEST32.
24	agent	Char	4	\$4.	\$4.
7	arrival_date_day_of_month	Num	8	BEST12.	BEST32.
5	arrival_date_month	Char	9	\$9.	\$9.
6	arrival_date_week_number	Num	8	BEST12.	BEST32.
4	arrival_date_year	Num	8	BEST12.	BEST32.
21	assigned_room_type	Char	1	\$1.	\$1.
12	babies	Num	8	BEST12.	BEST32.
22	booking_changes	Num	8	BEST12.	BEST32.
11	children	Char	2	\$2.	\$2.
25	company	Char	4	\$4.	\$4.
14	country	Char	4	\$4.	\$4.
27	customer_type	Char	15	\$15.	\$15.
26	days_in_waiting_list	Num	8	BEST12.	BEST32.
23	deposit_type	Char	10	\$10.	\$10.
16	distribution_channel	Char	9	\$9.	\$9.
1	hotel	Char	12	\$12.	\$12.
2	is_canceled	Num	8	BEST12.	BEST32.
17	is_repeated_guest	Num	8	BEST12.	BEST32.
3	lead_time	Num	8	BEST12.	BEST32.
15	market_segment	Char	13	\$13.	\$13.
13	meal	Char	9	\$9.	\$9.
19	previous_bookings_not_canceled	Num	8	BEST12.	BEST32.
18	previous_cancellations	Num	8	BEST12.	BEST32.
29	required_car_parking_spaces	Num	8	BEST12.	BEST32.
31	reservation_status	Char	9	\$9.	\$9.
32	reservation_status_date	Num	8	YYMMDD10.	YYMMDD10.
20	reserved_room_type	Char	1	\$1.	\$1.
9	stays_in_week_nights	Num	8	BEST12.	BEST32.
8	stays_in_weekend_nights	Num	8	BEST12.	BEST32.
30	total_of_special_requests	Num	8	BEST12.	BEST32.

Engine/Host Dependent Information	
Data Set Page Size	131072
Number of Data Set Pages	227
First Data Page	1
Max Obs per Page	528
Obs in First Data Page	502
Number of Data Set Repairs	0
Filename	/home/u64504352/Proiect_pachete/rezervari_brute.sas7bdat
Release Created	9.0401M8
Host Created	Linux
Inode Number	2193842394
Access Permission	rw-r--r--
Owner Name	u64504352
File Size	29MB
File Size (bytes)	29884416

The CONTENTS Procedure			
Data Set Name	PROIECT.REZERVARI_BRUTE	Observations	119390
Member Type	DATA	Variables	32
Engine	V9	Indexes	0
Created	19.05.2026 21:35:13	Observation Length	248
Last Modified	19.05.2026 21:35:13	Deleted Observations	0
Protection		Compressed	NO
Data Set Type		Sorted	NO
Label			
Data Representation	SOLARIS_X86_64, LINUX_X86_64, ALPHA_TRU64, LINUX_IA64		
Encoding	utf-8 Unicode (UTF-8)		

Figurile 11.1 – 11.3. Output-ul PROC CONTENTS pe trei panouri: (1) lista alfabetică a celor 32 de variabile cu tipuri Char/Num și informații despre format și informat; (2) sumarul setului de date (număr de observații, număr de variabile, locație fizică); (3) detalii complementare ale structurii (engine, indexare, etichete).

e) Interpretarea economică a rezultatelor

Importul controlat al datelor și verificarea structurii reprezintă fundamentul oricărei analize riguroase. Deducerea greșită a tipurilor (de exemplu, ADR salvat ca text din cauza unei valori formate diferit) ar fi blocat ulterior toate procedurile statistice și ar fi necesitat intervenție manuală costisitoare. Folosirea bibliotecii persistente proiect permite păstrarea datelor între sesiuni, fără re-import.

Facilitatea 2 — Crearea și folosirea de formate definite de utilizator

a) Definirea problemei

Variabilele categorice codificate numeric (is_canceled cu valorile 0/1) sau pe categorii naturale (lunile calendaristice ca text) sunt greu de interpretat în rapoarte și tabele de frecvențe. Pentru ca rapoartele să fie ușor de înțeles de către factorii decizionali, este necesară construcția unor formate definite de utilizator care să mapeze valorile tehnice în etichete cu semnificație business.

b) Informații necesare pentru rezolvare

Sunt necesare: variabilele is_canceled (0/1) și arrival_date_month (string), procedura PROC FORMAT pentru definirea formatelor, instrucțiunea FORMAT din interiorul PROC FREQ pentru aplicarea lor.

c) Metode de calcul, algoritmi și formule utilizate

- PROC FORMAT; VALUE cancel_fmt 0='Onorat' 1='Anulat'; RUN; — definirea formatului numeric;
- VALUE \$season_fmt 'December','January','February' = 'Iarna' ... — definirea formatului alfanumeric (prefixul \$ marchează aplicarea pe Char) cu gruparea lunilor în anotimpuri;
- Aplicarea în PROC FREQ: FORMAT is_canceled cancel_fmt. arrival_date_month \$season_fmt.;
- Avantaj: formatele nu modifică datele subiacente, doar prezentarea lor.

d) Prezentarea rezultatelor

Tabelele de frecvențe generate prin PROC FREQ afișează etichete comprehensibile: Onorat / Anulat pentru is_canceled, iar lunile sunt grupate în Iarna / Primavara / Vara / Toamna, evidențiind concentrarea cererii în sezonul cald (Vara) cu aproximativ o treime din volumul total.

Verificare Formate - Structura Rezervarilor si Sezoanelor				
The FREQ Procedure				
is_canceled	Frequency	Percent	Cumulative Frequency	Cumulative Percent
Onorat	75166	62.96	75166	62.96
Anulat	44224	37.04	119390	100.00

arrival_date_month	Frequency	Percent	Cumulative Frequency	Cumulative Percent
Primavara	32674	27.37	32674	27.37
Vara	37477	31.39	70151	58.76
Iarna	20777	17.40	90928	76.16
Toamna	28462	23.84	119390	100.00

Figura 12.1. Tabelul de frecvențe rezultat după aplicarea formatelor definite de utilizator.

e) Interpretarea economică a rezultatelor

Formatele utilizator transformă rapoartele tehnice în instrumente decizionale: managerul vede direct procentul rezervărilor anulate și distribuția sezonieră fără a necesita un dicționar de coduri. Această abordare reflectă bune practici de raportare în mediile enterprise, unde stratul de prezentare este separat conceptual de stratul de date.

Facilitatea 3 — Procesarea iterativă și condițională a datelor

a) Definirea problemei

Construcția variabilelor derivate (precum `total_nights`, suma nopților de weekend și de zilele lucrătoare) și clasificarea fiecărei rezervări într-o categorie de fereastră de rezervare (Last Minute, Termen Scurt, Termen Lung) sunt operații inerent iterative — se aplică observație cu observație pe parcursul setului de date — și condiționale — depind de valoarea variabilei `lead_time`. SAS oferă pentru aceste operații pasul DATA, mediul nativ de programare procedurală secvențială.

b) Informații necesare pentru rezolvare

Sunt necesare: setul de date `proiect.rezervari_brute`, variabilele `stays_in_weekend_nights`, `stays_in_week_nights`, `lead_time`; sintaxa instrucțiunilor IF/THEN/ELSE și DELETE din pasul DATA.

c) Metode de calcul, algoritmi și formule utilizate

- DATA proiect.rezervari_procesate_durata; SET proiect.rezervari_brute; — deschiderea unui pas DATA care iterează implicit pe toate observațiile;
- total_nights = stays_in_weekend_nights + stays_in_week_nights; — calcularea variabilei derivate;
- IF total_nights = 0 THEN DELETE; — filtrarea rezervărilor invalide (observații fără sens business);
- IF lead_time < 7 THEN lead_type = 'Last Minute'; ELSE IF lead_time <= 30 THEN lead_type = 'Termen Scurt'; ELSE lead_type = 'Termen Lung'; — clasificarea condițională în trei categorii de fereastră.

d) Prezentarea rezultatelor

Setul de date rezultat conține o variabilă total_nights derivată cu valori întregi pozitive, eliminând cele aproximativ 715 rezervări fără nopți de cazare. Distribuția lead_type evidențiază trei segmente distincte cu volume diferite, vizibile în output-ul PROC PRINT.

Obs	stays_in_weekend_nights	stays_in_week_nights	total_nights	lead_time	lead_type
1	0	1	1	7	Termen Scurt
2	0	1	1	13	Termen Scurt
3	0	2	2	14	Termen Scurt
4	0	2	2	14	Termen Scurt
5	0	2	2	0	Last Minute
6	0	2	2	9	Termen Scurt
7	0	3	3	85	Termen Lung
8	0	3	3	75	Termen Lung
9	0	4	4	23	Termen Scurt
10	0	4	4	35	Termen Lung

Figura 13.1. Primele zece observații cu variabilele derivate și categoria lead_type alocată condițional.

e) Interpretarea economică a rezultatelor

Segmentarea ferestrei de rezervare permite construirea unor politici tarifare diferențiate per categorie: Last Minute (lead time sub 7 zile) poate fi tarifat mai agresiv pentru a maximiza venitul ultimei minute; Termen Lung (peste 30 de zile) este eligibil pentru programe early-bird; Termen Scurt reprezintă un segment intermediar potrivit pentru oferte punctuale (weekend escape, city break).

Facilitatea 4 — Crearea de subseturi de date

a) Definirea problemei

Analizele specifice unor segmente — de exemplu, doar rezervările anulate (pentru investigarea factorilor de risc) sau doar hotelurile de tip resort (pentru profilarea comportamentului de vacanță) — necesită izolarea subseturilor relevante. SAS oferă două mecanisme pentru aceasta: clauza WHERE în pasul DATA (filtrare la nivelul observațiilor) și clauza KEEP/DROP (restricționarea variabilelor).

b) Informații necesare pentru rezolvare

Sunt necesare: setul de date proiect.rezervari_procesate_durata; variabilele is_canceled și hotel pe care se aplică condițiile de filtrare.

c) Metode de calcul, algoritmi și formule utilizate

- DATA proiect.subset_rezervari_anulate; SET proiect.rezervari_procesate_durata; WHERE is_canceled = 1; RUN; — subsetul rezervărilor anulate;
- DATA proiect.subset_hoteluri_resort; SET proiect.rezervari_procesate_durata; WHERE hotel = 'Resort Hotel'; RUN; — subsetul hotelurilor de tip resort;
- PROC PRINT cu opțiunea OBS=10 pentru verificare vizuală.

d) Prezentarea rezultatelor

Cele două subseturi izolează aproximativ 44.000 rezervări anulate și respectiv aproximativ 40.000 rezervări de tip resort, gata pentru analize țintite. Procedura PROC PRINT confirmă filtrarea corectă: toate observațiile din subset_hoteluri_resort au valoarea Resort Hotel pe coloana hotel.

Verificare Subset - Doar Hoteluri Resort

Obs	hotel	is_canceled	lead_time	total_nights
1	Resort Hotel	0	7	1
2	Resort Hotel	0	13	1
3	Resort Hotel	0	14	2
4	Resort Hotel	0	14	2
5	Resort Hotel	0	0	2
6	Resort Hotel	0	9	2
7	Resort Hotel	1	85	3
8	Resort Hotel	1	75	3
9	Resort Hotel	1	23	4
10	Resort Hotel	0	35	4

Figura 14.1. Primele zece observații ale subsetului Resort Hotel.

e) Interpretarea economică a rezultatelor

Subsetarea oferă investitorului perspective dedicate asupra fiecărui segment operațional. Resort Hotel manifestă comportament de vacanță (sejururi mai lungi, sezonabilitate accentuată, dependență de cerere internațională), în timp ce City Hotel are profil business (sejururi scurte, cerere stabilă, anulări mai frecvente). Diferențierea informează decizii de pricing și marketing per tip de hotel.

Facilitatea 5 — Utilizarea funcțiilor SAS (ROUND, PUT, UPCASE)

a) Definirea problemei

Calculul venitului generat de fiecare rezervare necesită operații aritmetice precise rotunjite la două zecimale (în euro), iar standardizarea codurilor de țară (anumite înregistrări pot fi în litere mici) și conversia anului numeric într-un format text pentru raportare reclamă funcții specializate. Pachetul SAS oferă o bibliotecă bogată de funcții intrinseci atât pentru valori numerice, cât și pentru manipularea textului.

b) Informații necesare pentru rezolvare

Sunt necesare: variabilele `total_nights`, `adr` (numerice), `arrival_date_year` (numerică), `country` (alfanumerică); funcțiile `ROUND`, `PUT`, `UPCASE`.

c) Metode de calcul, algoritmi și formule utilizate

- `revenue = ROUND(total_nights * adr, 0.01)`; — calculul venitului cu rotunjire la cent;
- `arrival_year_str = PUT(arrival_date_year, 4.)`; — conversie numerică → text fix de 4 caractere;
- `country_upper = UPCASE(country)`; — standardizare la majuscule pentru consistență cu shapefile-uri și join-uri.

d) Prezentarea rezultatelor

Tabelul rezultat afișează venitul calculat per rezervare (`revenue`), alături de variabilele auxiliare `arrival_year_str` (folosit pentru concatenări de etichete) și `country_upper` (folosit la join-uri cu seturi externe care folosesc codificare uniformă în majuscule).

Obs	hotel	adr	total_nights	revenue	arrival_date_year	arrival_year_str	country	country_upper
1	Resort Hotel	75	1	75.0	2015	2015	GBR	GBR
2	Resort Hotel	75	1	75.0	2015	2015	GBR	GBR
3	Resort Hotel	98	2	196.0	2015	2015	GBR	GBR
4	Resort Hotel	98	2	196.0	2015	2015	GBR	GBR
5	Resort Hotel	107	2	214.0	2015	2015	PRT	PRT
6	Resort Hotel	103	2	206.0	2015	2015	PRT	PRT
7	Resort Hotel	82	3	246.0	2015	2015	PRT	PRT
8	Resort Hotel	105.5	3	316.5	2015	2015	PRT	PRT
9	Resort Hotel	123	4	492.0	2015	2015	PRT	PRT
10	Resort Hotel	145	4	580.0	2015	2015	PRT	PRT

Figura 15.1. Primele zece observații cu venitul calculat și variabilele standardizate.

e) Interpretarea economică a rezultatelor

Calculul precis al venitului per rezervare este fundamentul evaluării pierderilor directe cauzate de anulări. Agregat pe întregul set și pe subsetul rezervărilor anulate, indicatorul cuantifică în euro impactul anulărilor — argument numeric pentru investiția într-un sistem de scoring și retenție. Standardizarea textului previne erori subtile la join-uri (de exemplu, `PRT` versus `prt` ar fi considerate categorii diferite).

Facilitatea 6 — Combinarea seturilor de date prin proceduri SQL

a) Definirea problemei

Raportarea prețului fiecărei rezervări nu doar în valoare absolută, ci și relativ la media lunii respective (`price_deviation`), necesită o operație de tip `self-join`: agregarea într-o tabelă

auxiliară a mediei lunare per hotel, urmată de îmbinarea acestei tabele cu tabela principală pe cheia compusă (hotel, lună). Procedura PROC SQL oferă în SAS sintaxa standard SQL pentru aceste operații.

b) Informații necesare pentru rezolvare

Sunt necesare: setul de date proiect.rezervari_venituri_calculate; sintaxa CREATE TABLE AS SELECT, GROUP BY, INNER JOIN.

c) Metode de calcul, algoritmi și formule utilizate

- CREATE TABLE proiect.medii_pret_tip_hotel AS SELECT hotel, arrival_date_month, MEAN(adr) AS avg_monthly_adr FROM ... GROUP BY hotel, arrival_date_month; — agregarea mediei lunare per hotel;
- CREATE TABLE proiect.rezervari_deviatie_tarifara AS SELECT a.*, b.avg_monthly_adr, (a.adr - b.avg_monthly_adr) AS price_deviation FROM ... a INNER JOIN ... b ON a.hotel=b.hotel AND a.arrival_date_month=b.arrival_date_month; — îmbinarea pe cheie compusă;
- FORMAT 8.2 — afișarea cu două zecimale a coloanei numerice.

d) Prezentarea rezultatelor

Tabelul rezultat conține pentru fiecare rezervare valoarea deviației față de media lunară a aceluiași tip de hotel: valori pozitive indică rezervări tarifate peste medie (premiu de preț), valori negative indică rezervări sub medie (potențiale discount-uri).

Obs	hotel	arrival_date_month	adr	avg_monthly_adr	price_deviation
1	Resort Hotel	July	75	156.59	-81.59
2	Resort Hotel	July	75	156.59	-81.59
3	Resort Hotel	July	98	156.59	-58.59
4	Resort Hotel	July	98	156.59	-58.59
5	Resort Hotel	July	107	156.59	-49.59
6	Resort Hotel	July	103	156.59	-53.59
7	Resort Hotel	July	82	156.59	-74.59
8	Resort Hotel	July	105.5	156.59	-51.09
9	Resort Hotel	July	123	156.59	-33.59
10	Resort Hotel	July	145	156.59	-11.59

Figura 16.1. Tabelul rezultat după INNER JOIN: prețul fiecărei rezervări, media lunară și deviația individuală.

e) Interpretarea economică a rezultatelor

Deviația de preț oferă un indicator de eficiență a vânzării camerei: rezervări cu deviație pozitivă mare reprezintă oferte premium plasate în vârf de cerere; cele cu deviație negativă mare semnalează vânzări rapide sau discount-uri ad-hoc. Distribuția deviațiilor pe segmente (market_segment, customer_type) ar putea evidenția canalele cele mai profitabile sau, dimpotrivă, cele care erodează marja medie.

Facilitatea 7 — Utilizarea masivelor (ARRAY) pentru normalizare min-max

a) Definirea problemei

Aplicarea modelelor de învățare automată — inclusiv regresia logistică — necesită aducerea variabilelor numerice la o scară comună, pentru ca magnitudinile diferite (lead_time în [0; 737] zile vs ADR în [0; 220] €) să nu denatureze coeficienții. Normalizarea Min-Max — aducerea valorilor în intervalul [0, 1] — este o operație vectorială aplicată simultan pe mai multe coloane. SAS oferă pentru aceste cazuri construcția ARRAY, care grupează mai multe variabile sub un nume colectiv și permite operarea pe ele într-o buclă DO.

b) Informații necesare pentru rezolvare

Sunt necesare: variabilele lead_time și adr, valorile globale ale minimului și maximumului fiecăreia (extrase printr-un PROC SQL anterior într-o macro-variabilă), instrucțiunea ARRAY și bucla DO.

c) Metode de calcul, algoritmi și formule utilizate

- PROC SQL NOPRINT; SELECT MIN(lead_time), MAX(lead_time), MIN(adr), MAX(adr) INTO :min_lt, :max_lt, :min_adr, :max_adr FROM ...; QUIT; — extragerea extremelor în macro-variabile;
- ARRAY orig{2} lead_time adr; — declararea masivului cu variabilele originale;
- ARRAY norm{2} norm_lead_time norm_adr; — declararea masivului-rezultat;
- ARRAY mn{2} _TEMPORARY_ (&min_lt, &min_adr); — masive temporare cu extremele;
- DO i = 1 TO 2; IF (mx{i} - mn{i}) > 0 THEN norm{i} = (orig{i} - mn{i}) / (mx{i} - mn{i}); ELSE norm{i} = 0; END; — bucla de normalizare aplicată uniform pe ambele variabile.

d) Prezentarea rezultatelor

Setul de date rezultat conține coloanele norm_lead_time și norm_adr cu valori strict în intervalul [0, 1], gata pentru a fi folosite ca predictorii în PROC LOGISTIC (facilitatea 9).

Tabelul de control afișează valorile originale și cele normalizate pentru primele zece observații, confirmând coerența transformării.

Obs	lead_time	norm_lead_time	adr	norm_adr
1	7	0.00987	75	0.015053
2	13	0.01834	75	0.015053
3	14	0.01975	98	0.019307
4	14	0.01975	98	0.019307
5	0	0.00000	107	0.020972
6	9	0.01269	103	0.020232
7	85	0.11989	82	0.016347
8	75	0.10578	105.5	0.020694
9	23	0.03244	123	0.023931
10	35	0.04937	145	0.028000

Figura 17.1. Variabilele `lead_time` și `adr` înainte și după normalizarea min-max aplicată prin `ARRAY` și buclă `DO`.

e) Interpretarea economică a rezultatelor

Normalizarea garantează că în modelul de regresie logistică toate variabilele contribuie la log-odds-ul anulării pe o scară comparabilă, permițând interpretarea coeficienților standardizați ca măsură directă a importanței fiecărui predictor. Folosirea `ARRAY`-urilor în loc de scrierea secvențială a câte unei instrucțiuni per variabilă reduce dimensiunea codului și mărește reutilizabilitatea — extinderea la mai multe variabile presupune doar mărirea dimensiunii masivelor.

Facilitatea 8 — Proceduri de raportare (PROC FREQ, PROC REPORT)

a) Definirea problemei

Generarea unui raport executiv care sumarizeze indicatorii operaționali pe dimensiuni-cheie (luna calendaristică, tipul de client) este o necesitate recurentă în mediile enterprise. SAS oferă două proceduri complementare: `PROC FREQ` pentru distribuții bivariate (tabele de

contingență) și PROC REPORT pentru rapoarte multi-coloană cu agregări personalizate per coloană.

b) Informații necesare pentru rezolvare

Sunt necesare: setul de date proiect.rezervari_deviatie_tarifara; variabilele customer_type, is_canceled, arrival_date_month, adr, total_nights; opțiunile de formatare ale PROC REPORT.

c) Metode de calcul, algoritmi și formule utilizate

- PROC FREQ DATA=...; TABLES customer_type * is_canceled / NOROW NOCOL NOPERCENT; RUN; — tabel de contingență tip $\times$ anulare cu frecvențe brute;
- PROC REPORT DATA=... NOWINDOWS HEADLINE; COLUMN arrival_date_month is_canceled adr total_nights; DEFINE arrival_date_month / GROUP 'Luna calendaristica'; DEFINE is_canceled / ANALYSIS MEAN 'Rata mediei de anulare' FORMAT=PERCENT8.2; ... — raport multi-coloană cu agregări diferite per coloană (MEAN pe rate, SUM pe volume).

d) Prezentarea rezultatelor

Tabelul PROC FREQ evidențiază o pondere foarte mare a clientelei Transient (aproximativ 75 % din total) și o rată de anulare diferențiată pe tipul de client — Transient și Transient-Party prezintă rate ridicate, în timp ce Contract (rezervări corporate cu contracte) prezintă o rată semnificativ mai scăzută. Raportul executiv PROC REPORT sumarizează pe lună: rata medie de anulare, prețul mediu și volumul total al nopților, oferind o vedere sinoptică a sezonality.

Raport Frecvente - Anulari in functie de tipul de client

The FREQ Procedure

Frequency	Table of customer_type by is_canceled		
	is_canceled		
customer_type	0	1	Total
Contract	2797	1262	4059
Group	513	58	571
Transient	52525	38482	89007
Transient-Party	18851	6387	25038
Total	74486	44189	118675

Raport Executiv - Performanta si Rata de Anulare pe Luni			
Luna calendaristica	Rata mediei de anulare	Pret mediu incasat (ADR)	Total nopti rezervate
April	40.87%	100.73	37335
August	37.88%	140.63	54077
December	35.35%	82.11	21849
February	33.57%	74.14	24455
January	30.70%	71.00	17618
July	37.62%	127.39	49705
June	41.60%	117.12	39116
March	32.35%	81.23	33489
May	39.92%	109.43	38634
November	31.55%	74.57	21667
October	38.33%	88.59	34887
September	39.25%	105.28	36425

Figurile 18.1 și 18.2. Tabelul de contingență Customer × Cancel (PROC FREQ) și raportul executiv lunar (PROC REPORT).

e) Interpretarea economică a rezultatelor

Distribuția rezervărilor pe tipul de client orientează strategia comercială: deși segmentul Transient generează volumul, rata mare de anulare (peste 40 % într-un grup) îi limitează contribuția netă; segmentul Contract — mai puțin numeros, dar cu rată scăzută a anulărilor — este candidat pentru parteneriate corporate stabile. Raportul lunar evidențiază lunile de risc maxim (cu rate mari și volume mari simultan), unde intervențiile preventive au impact maxim.

Facilitatea 9 — Proceduri statistice și ML: regresia logistică (PROC LOGISTIC)

a) Definirea problemei

Replicarea independentă a modelului de predicție a anulării — construit în Python — folosind motorul statistic propriu pachetului SAS oferă o validare metodologică încrucișată: dacă cele două modele converg asupra factorilor predictivi cheie, concluziile pot fi prezentate cu un grad mai mare de încredere. Procedura PROC LOGISTIC este referința SAS pentru regresia logistică binară.

b) Informații necesare pentru rezolvare

Sunt necesare: setul de date proiect.rezervari_normalizate_ml (cu predictorii normalizați min-max prin ARRAY în facilitatea 7); variabilele categorice hotel și deposit_type configurate prin instrucțiunea CLASS; specificarea modelului prin instrucțiunea MODEL.

c) Metode de calcul, algoritmi și formule utilizate

- PROC LOGISTIC DATA=... DESCENDING; — opțiunea DESCENDING forțează modelarea $P(\text{is_canceled} = 1)$, nu $P(\text{is_canceled} = 0)$;
- CLASS hotel (REF='City Hotel') deposit_type (REF='No Deposit') / PARAM=REF; — variabilele categorice cu codificare REF (efectele se interpretează ca diferențe față de categoria de referință);
- MODEL is_canceled = norm_lead_time norm_adr total_nights hotel deposit_type; — specificarea formulei modelului;
- SCORE OUT=proiect.predictii_anulare_logistic OUTROC=proiect.date_curba_roc_logistic; — salvarea predicțiilor probabilistice și a punctelor curbei ROC.

d) Prezentarea rezultatelor

Modelul converge după 4 iterații Fisher's scoring și produce un AUC de 0,7493 (validare independentă, ușor mai conservatoare decât AUC-ul Python). Tabelul Maximum Likelihood Estimates evidențiază estimări semnificative statistic ($p < 0,0001$) pentru toți predictorii principali: norm_lead_time ($\beta = 2,31$), norm_adr ($\beta = 24,89$), total_nights ($\beta = 0,047$), hotel = Resort ($\beta = -0,34$, $p < 0,0001$) și mai ales deposit_type = Non Refund ($\beta = 5,72$, $p < 0,0001$).

Antrenare Model ML - Regresie Logistica

The LOGISTIC Procedure

Model Information	
Data Set	PROIECT.REZERVARI_NORMALIZE_ML
Response Variable	is_canceled
Number of Response Levels	2
Model	binary logit
Optimization Technique	Fisher's scoring

Number of Observations Read	118875
Number of Observations Used	118875

Response Profile		
Ordered Value	is_canceled	Total Frequency
1	1	44189
2	0	74486

Probability modeled is is_canceled='1'.

Class Level Information			
Class	Value	Design Variables	
hotel	City Hotel	0	
	Resort Hotel	1	
deposit_type	No Deposit	0	0
	Non Refund	1	0
	Refundable	0	1

Model Convergence Status
Convergence criterion (GCONV=1E-8) satisfied.

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	156699.56	121445.66
SC	156709.24	121513.45
-2 Log L	156697.56	121431.66


Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	35265.8979	6	<.0001
Score	30575.8845	6	<.0001
Wald	7060.7537	6	<.0001

Type 3 Analysis of Effects			
Effect	DF	Wald Chi-Square	Pr > ChiSq
norm_lead_time	1	1943.6281	<.0001
norm_adr	1	1064.8313	<.0001
total_nights	1	290.8048	<.0001
hotel	1	482.0309	<.0001
deposit_type	2	3000.8286	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	-1.8010	0.0212	7202.4508	<.0001
norm_lead_time		1	2.3114	0.0524	1943.6281	<.0001
norm_adr		1	24.8913	0.7628	1064.8313	<.0001
total_nights		1	0.0467	0.00274	290.8048	<.0001
hotel	Resort Hotel	1	-0.3422	0.0156	482.0309	<.0001
deposit_type	Non Refund	1	5.7200	0.1045	2998.5517	<.0001
deposit_type	Refundable	1	-0.2540	0.1829	1.7347	0.1878

Odds Ratio Estimates			
Effect	Point Estimate	95% Wald Confidence Limits	
norm_lead_time	10.088	9.103	11.180
norm_adr	>999.999	>999.999	>999.999
total_nights	1.048	1.042	1.053
hotel Resort Hotel vs City Hotel	0.710	0.689	0.732
deposit_type Non Refund vs No Deposit	304.914	248.464	374.191
deposit_type Refundable vs No Deposit	0.776	0.532	1.132

Association of Predicted Probabilities and Observed Responses			
Percent Concordant	74.9	Somers' D	0.499
Percent Discordant	25.1	Gamma	0.499
Percent Tied	0.0	Tau-a	0.233
Pairs	3291461854	c	0.749



Figurile 19.1 – 19.8. Output-ul complet al PROC LOGISTIC: (1) informațiile despre model; (2) profilul răspunsului (frecvența claselor 0/1); (3) istoricul iterativ al convergenței Fisher's scoring; (4) statisticile globale ale fit-ului — AIC, SC, $-2 \log L$ și testele Likelihood Ratio, Score și Wald; (5) tabelul Maximum Likelihood Estimates cu coeficienții, erorile standard, statisticile Wald Chi-Square și p-value-urile; (6) odds ratio estimates cu intervale de încredere 95 %; (7) statisticile de asociere între predicții și observații; (8) curba ROC cu aria sub curbă (AUC) = 0,7493.

e) Interpretarea economică a rezultatelor

Convergența rezultatelor SAS și Python asupra aceluiași clasament al predictorilor — depozitul non-refundabil ca factor anti-anulare dominant, lead time și ADR ca factori de risc — întărește încrederea în concluziile metodologice. Coeficientul puternic pozitiv al variabilei deposit_type = Non Refund (interpretat aici inversat din cauza modelării $P(\text{is_canceled} = 1)$ cu codificare REF) confirmă mecanismul economic: clienții care plătesc în avans non-refundabil rar anulează — efectul de sunk cost este puternic.

Facilitatea 10 — Generarea graficelor (PROC SGPLOT, PROC SGPANEL)

a) Definirea problemei

Comunicarea eficientă a rezultatelor către factorii decizionali necesită vizualizări care să transmită concis structura datelor. SAS oferă două proceduri grafice complementare: PROC SGPLOT (un singur panou) și PROC SGPANEL (mai multe panouri co-organizate, util pentru comparații between-groups). Selecția tipurilor de grafice — boxplot pentru distribuția prețurilor, bar chart paralel pentru anulări pe fereastră de rezervare, line plot pentru evoluția lunară — reflectă bune practici de raportare vizuală.

b) Informații necesare pentru rezolvare



Sunt necesare: setul de date proiect.rezervari_deviatie_tarifara; variabilele adr, hotel, lead_type, is_canceled, arrival_date_month; instrucțiunile VBOX, VBAR, SERIES.


c) Metode de calcul, algoritmi și formule utilizate

- PROC SGPLOT cu VBOX adr / CATEGORY=hotel — boxplot vertical al ADR pe tipul de hotel, evidențiind distribuția (mediană, cuartile, outlieri);
- PROC SGPANEL cu PANELBY hotel / COLUMNS=2 și VBAR lead_type / GROUP=is_canceled GROUPDISPLAY=CLUSTER — bar chart cluster, comparativ pe ferestre de rezervare și pe stare (Onorat/Anulat), separat pe tipul de hotel;
- PROC SQL pentru agregarea prealabilă a mediilor lunare per hotel, urmată de PROC SGPLOT cu SERIES X=arrival_date_month Y=adr_mediu / GROUP=hotel — linii temporale comparative.

d) Prezentarea rezultatelor

Graficul 1 (boxplot ADR pe hotel) evidențiază că City Hotel are o distribuție mai concentrată în jurul mediane (~100 €) iar Resort prezintă o dispersie mai mare cu mediana similară (~95 €). Graficul 2 (bar chart lead_type × is_canceled per hotel) arată că rezervările Termen Lung — categoria dominantă — generează majoritatea anulărilor. Graficul 3 (evoluție lunară) confirmă vârful de preț din sezonul cald, în special pentru Resort Hotel.





Figurile 20.1 – 20.3. Boxplot ADR pe hotel (SGPLOT), bar chart Anulări $\times$ Lead Type pe panouri (SGPANEL) și evoluția lunară a ADR (SGPLOT cu serii suprapuse).

e) Interpretarea economică a rezultatelor

Vizualizările sintetizează grafic concluziile cantitative ale facilităților anterioare: asimetria distribuției ADR justifică log-transformarea folosită în regresia OLS; concentrarea anulărilor pe ferestre lungi de rezervare validează strategia de intervenții la 14/7 zile înainte de check-in; vârful sezonier al ADR-ului fundamentează calibrarea bugetului de marketing pe trimestre.

ANEXA A — CODUL SURSĂ SAS

Această anexă prezintă codul SAS folosit pentru implementarea fiecărei facilități, exact așa cum a fost rulat în mediul SAS On Demand. Codul este organizat pe cele zece facilități descrise în Partea II și folosește biblioteca persistentă <proiect> pentru stocarea seturilor de date intermediare.

Facilitatea 1 — PROC IMPORT și PROC CONTENTS

```
PROC IMPORT
  DATAFILE="/home/u64504352/Proiect_pachete/hotel_bookings.csv"
  OUT=proiect.rezervari_brute
  DBMS=CSV
  REPLACE;
  GUESSINGROWS=MAX;
  GETNAMES=YES;
RUN;
PROC CONTENTS DATA=proiect.rezervari_brute;
RUN;
```

Facilitatea 2 — PROC FORMAT și aplicarea formatelor în PROC FREQ

```
PROC FORMAT;
  VALUE cancel_fmt
    0 = 'Onorat'
    1 = 'Anulat';
  VALUE $season_fmt
    'December','January','February' = 'Iarna'
    'March','April','May' = 'Primavara'
    'June','July','August' = 'Vara'
    'September','October','November' = 'Toamna';
RUN;
TITLE "Verificare Formate - Structura Rezervarilor si Sezoanelor";
PROC FREQ DATA=proiect.rezervari_brute;
  TABLES is_canceled arrival_date_month;
  FORMAT is_canceled cancel_fmt. arrival_date_month $season_fmt.;
RUN;
TITLE;
```

Facilitatea 3 — Procesare iterativă și condițională în DATA step

```
DATA proiect.rezervari_procesate_durata;
  SET proiect.rezervari_brute;
  /* Calculul totalului noptilor de cazare */
  total_nights = stays_in_weekend_nights + stays_in_week_nights;
  /* Filtrare rezervari invalide */
  IF total_nights = 0 THEN DELETE;
  /* Clasificarea ferestrei de rezervare */
  IF lead_time < 7 THEN lead_type = 'Last Minute';
  ELSE IF lead_time <= 30 THEN lead_type = 'Termen Scurt';
```

```

        ELSE lead_type = 'Termen Lung';
RUN;
PROC PRINT DATA=proiect.rezervari_procesate_durata (OBS=10);
    VAR stays_in_weekend_nights stays_in_week_nights total_nights
    lead_time lead_type;
RUN;

```

Facilitatea 4 — Subseturi de date prin clauza WHERE

```

/* Subset pentru rezervarile anulate */
DATA proiect.subset_rezervari_anulate;
    SET proiect.rezervari_procesate_durata;
    WHERE is_canceled = 1;
RUN;
/* Subset pentru hotelurile de tip Resort */
DATA proiect.subset_hoteluri_resort;
    SET proiect.rezervari_procesate_durata;
    WHERE hotel = 'Resort Hotel';
RUN;
TITLE "Verificare Subset - Doar Hoteluri Resort";
PROC PRINT DATA=proiect.subset_hoteluri_resort (OBS=10);
    VAR hotel is_canceled lead_time total_nights;
RUN;
TITLE;

```

Facilitatea 5 — Funcții SAS (ROUND, PUT, UPCASE)

```

DATA proiect.rezervari_venituri_calculate;
    SET proiect.rezervari_procesate_durata;
    /* Functia ROUND - calcul venit cu 2 zecimale */
    revenue = ROUND(total_nights * adr, 0.01);
    /* Functia PUT - conversie an in text */
    arrival_year_str = PUT(arrival_date_year, 4.);
    /* Functia UPCASE - standardizare cod tara */
    country_upper = UPCASE(country);
RUN;
PROC PRINT DATA=proiect.rezervari_venituri_calculate (OBS=10);
    VAR hotel adr total_nights revenue arrival_date_year arrival_year_str
    country country_upper;
RUN;

```

Facilitatea 6 — Combinare prin PROC SQL (GROUP BY + INNER JOIN)

```

PROC SQL;
    /* Cream tabelul cu mediile lunare */
    CREATE TABLE proiect.medii_pret_tip_hotel AS
    SELECT hotel, arrival_date_month, MEAN(adr) AS avg_monthly_adr
    FORMAT=8.2
    FROM proiect.rezervari_venituri_calculate
    GROUP BY hotel, arrival_date_month;
    /* Combinam tabelul principal cu cel de medii */
    CREATE TABLE proiect.rezervari_deviatie_tarifara AS
    SELECT a.*, b.avg_monthly_adr,

```

```

        (a.adr - b.avg_monthly_adr) AS price_deviation FORMAT=8.2
FROM proiect.rezervari_venituri_calculate AS a
INNER JOIN proiect.medii_pret_tip_hotel AS b
ON a.hotel = b.hotel AND a.arrival_date_month = b.arrival_date_month;
QUIT;
PROC PRINT DATA=proiect.rezervari_deviatie_tarifara (OBS=10);
    VAR hotel arrival_date_month adr avg_monthly_adr price_deviation;
RUN;

```

Facilitatea 7 — Masive (ARRAY) pentru normalizarea min-max

```

PROC SQL NOPRINT;
    SELECT MIN(lead_time), MAX(lead_time), MIN(adr), MAX(adr)
    INTO :min_lt, :max_lt, :min_adr, :max_adr
    FROM proiect.rezervari_deviatie_tarifara;
QUIT;
DATA proiect.rezervari_normalizate_ml;
    SET proiect.rezervari_deviatie_tarifara;
    ARRAY orig{2} lead_time adr;
    ARRAY norm{2} norm_lead_time norm_adr;
    ARRAY mn{2} _TEMPORARY_ (&min_lt, &min_adr);
    ARRAY mx{2} _TEMPORARY_ (&max_lt, &max_adr);
    DO i = 1 TO 2;
        IF (mx{i} - mn{i}) > 0 THEN norm{i} = (orig{i} - mn{i}) / (mx{i}
- mn{i});
        ELSE norm{i} = 0;
    END;
    DROP i;
RUN;
PROC PRINT DATA=proiect.rezervari_normalizate_ml (OBS=10);
    VAR lead_time norm_lead_time adr norm_adr;
RUN;

```

Facilitatea 8 — Proceduri de raportare (PROC FREQ și PROC REPORT)

```

TITLE "Raport Frecvente - Anulari in functie de tipul de client";
PROC FREQ DATA=proiect.rezervari_deviatie_tarifara;
    TABLES customer_type * is_canceled / NOROW NOCOL NOPERCENT;
RUN;
TITLE "Raport Executiv - Performanta si Rata de Anulare pe Luni";
PROC REPORT DATA=proiect.rezervari_deviatie_tarifara NOWINDOWS HEADLINE;
    COLUMN arrival_date_month is_canceled adr total_nights;
    DEFINE arrival_date_month / GROUP 'Luna calendaristica';
    DEFINE is_canceled / ANALYSIS MEAN 'Rata mediei de anulare'
FORMAT=PERCENT8.2;
    DEFINE adr / ANALYSIS MEAN 'Pret mediu incasat (ADR)' FORMAT=8.2;
    DEFINE total_nights / ANALYSIS SUM 'Total nopti rezervate';
RUN;
TITLE;

```

Facilitatea 9 — Regresie logistică prin PROC LOGISTIC

```
TITLE "Antrenare Model ML - Regresie Logistica";
PROC LOGISTIC DATA=proiect.rezervari_normalizate_ml DESCENDING;
    CLASS hotel (REF='City Hotel') deposit_type (REF='No Deposit') /
PARAM=REF;
    MODEL is_canceled = norm_lead_time norm_adr total_nights hotel
deposit_type;
    /* Salvam predictiile si datele pentru graficul ROC */
    SCORE OUT=proiect.predictii_anulare_logistic
OUTROC=proiect.date_curba_roc_logistic;
RUN;
TITLE;
```

Facilitatea 10 — Generarea graficelor (PROC SGPLOT, PROC SGPANEL)

```
/* 1. Boxplot - Distributia tarifelor ADR pe tipuri de hotel */
TITLE "Grafic 1 - Distributia tarifelor ADR pe tipuri de hotel";
PROC SGPLOT DATA=proiect.rezervari_deviatie_tarifara;
    VBOX adr / CATEGORY=hotel FILLATTRS=(COLOR=lightblue);
    YAXIS LABEL='Pret ADR (EUR)' VALUES=(0 TO 400 BY 50);
RUN;
/* 2. Grafic pe panouri - Volumul anularilor in functie de fereastra de
rezervare */
TITLE "Grafic 2 - Volumul anularilor in functie de fereastra de
rezervare";
PROC SGPANEL DATA=proiect.rezervari_deviatie_tarifara;
    PANELBY hotel / COLUMNS=2 NOVARNAME;
    VBAR lead_type / GROUP=is_canceled GROUPDISPLAY=CLUSTER;
RUN;
/* 3. Line Plot - Evolutia pretului mediu (ADR) pe parcursul lunilor */
PROC SQL;
    CREATE TABLE proiect.trend_pret_lunar AS
    SELECT hotel, arrival_date_month, MEAN(adr) AS adr_mediu
    FROM proiect.rezervari_deviatie_tarifara
    GROUP BY hotel, arrival_date_month;
QUIT;
TITLE "Grafic 3 - Evolutia lunara a pretului mediu (ADR)";
PROC SGPLOT DATA=proiect.trend_pret_lunar;
    SERIES X=arrival_date_month Y=adr_mediu / GROUP=hotel MARKERS
LINEATTRS=(THICKNESS=2);
    XAXIS LABEL="Luna Sosirii";
    YAXIS LABEL="Pret Mediu (EUR)";
RUN;
TITLE;
```

CONCLUZII

Proiectul a abordat patru întrebări strategice asupra unui set de 119.390 de rezervări hoteliere europene, folosind un instrumentar dual Python/SAS care acoperă întregul flux analitic — de la auditul calității datelor și tratarea valorilor lipsă, până la modelarea predictivă a anulărilor și vizualizarea geografică a cererii.

Pe partea Python, aplicația Streamlit construită oferă un mediu de explorare interactivă în care utilizatorul poate ajusta în timp real strategiile de curățare (regulile $1,5 \cdot \text{IQR}$, $3 \cdot \text{IQR}$ sau prag fix pe ADR), algoritmi de scalare (StandardScaler vs MinMaxScaler), numărul de clustere (K între 2 și 10) și pragul de clasificare al regresiei logistice. Modelele econometrice produc rezultate stabile: regresia logistică obține un AUC ROC superior valorii de 0,83 cu rate de recall pe clasa anulărilor de aproximativ 79 %, iar regresia liniară multiplă OLS pe ADR atinge un R^2 ajustat în jur de 0,40, evidențiind ca predictorii semnificativi tipul depozitului, sezonabilitatea ciclică și mărimea grupului. Segmentarea K-means cu $K = 4$ produce profiluri comportamentale distincte, cu rate de anulare diferențiate per cluster.

Pe partea SAS, fluxul de lucru reproduce structura clasică a unui mediu enterprise: import controlat al datelor (PROC IMPORT), construcția de formate definite de utilizator (PROC FORMAT), procesare iterativă în DATA step, combinarea seturilor prin PROC SQL, raportare prin PROC REPORT și modelare predictivă prin PROC LOGISTIC. Modelul logistic SAS, antrenat pe variabilele normalizate min-max prin masive ARRAY, atinge un AUC de 0,7493, confirmând independent rezultatele Python și evidențiind aceiași factori explicativi dominanți — tipul depozitului non-refundabil reduce drastic probabilitatea de anulare.

Din perspectivă economică, analiza oferă investitorului trei pârghii operaționale concrete: (1) implementarea unui sistem proactiv de contact al clienților cu probabilitate de anulare peste 40 % poate reduce pierderile directe de venit cu 15–20 %; (2) tarifarea diferențiată pe segmente comportamentale (Last-minute · Preț scăzut versus Termen-lung · Preț ridicat) permite optimizarea ADR fără a sacrifica gradul de ocupare; (3) prioritizarea campaniilor de marketing către cele cinci țări dominante (Portugalia, Marea Britanie, Franța, Spania, Germania) sau, dimpotrivă, către piețele identificate în cadranul 'high-value, low-cancellation' al matricei strategice, fundamentează decizia de extindere geografică.

Limitările principale ale studiului provin din natura datasetului: acoperă un singur lanț hotelier european într-o perioadă de doi ani, fapt care restrânge generalizarea către alte segmente de piață (luxury, capsule, hostel) și către perioade extreme (pandemia COVID-19 a

alterat ulterior dinamica anulărilor în industria hotelieră, fapt nereflectat în date). Direcțiile viitoare pot include validarea modelelor pe seturi de date complementare, introducerea unor predictorii de tip macroeconomic (cursuri valutare, indici de turism) și extinderea segmentării prin tehnici suplimentare.

BIBLIOGRAFIE

1. Antonio, N., de Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. Data in Brief, 22, 41–49. DOI: 10.1016/j.dib.2018.11.126
2. Tukey, J. W. (1977). Exploratory Data Analysis. Reading, Massachusetts: Addison-Wesley Publishing Company.
3. Pedregosa, F., Varoquaux, G., Gramfort, A. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
4. Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. Proceedings of the 9th Python in Science Conference, 92–96.
5. Documentația oficială Streamlit: <https://docs.streamlit.io>
6. Documentația oficială scikit-learn: <https://scikit-learn.org/stable/>
7. Documentația oficială statsmodels: <https://www.statsmodels.org/stable/>
8. Documentația oficială geopandas: <https://geopandas.org/>
9. Natural Earth (free vector and raster map data): <https://www.naturalearthdata.com>
10. SAS Institute Inc. (2023). SAS/STAT 15.2 User's Guide. Cary, NC: SAS Institute Inc.s